

# 第三章 正态及学生-t 模型

Wang Shujia

## Contents

<b>1</b>	<b>一元正态模型 (单参数)</b>	<b>2</b>
1.1	方差已知 . . . . .	2
1.2	方差未知 . . . . .	3
<b>2</b>	<b>一元正态模型 (多参数: 均值与方差都未知)</b>	<b>5</b>
2.1	无信息先验 . . . . .	6
2.2	共轭先验 . . . . .	9
<b>3</b>	<b>多元正态模型</b>	<b>11</b>
3.1	多元正态分布及 Wishart 分布 . . . . .	11
3.2	多元正态模型 (协差阵 $\Sigma$ 已知) . . . . .	12
3.3	多元正态模型 (协差阵 $\Sigma$ 未知) . . . . .	12

# 1 一元正态模型（单参数）

## 1.1 方差已知

正态分布的定义

定义 1. 正态分布  $X \sim N(\mu, \sigma^2)$  的 pdf 为

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$$

- 方差的倒数  $\tau = 1/\sigma^2$  称为精度 (precision)
- 贝叶斯统计常用精度而不用方差。
- 在 WinBUGS 中, 正态分布记为  $X \sim N(\mu, \tau)$
- 本节分别讨论 Location( $\mu$ ) 和 scale ( $\sigma$ ) 的贝叶斯估计

正态模型（方差已知）：正态-正态模型

假设观察值  $\mathbf{x} = (x_1, \dots, x_n)'$  来自正态总体  $N(\mu, \sigma^2)$ ,  $\sigma^2$  已知。

如果先验分布也是正态:  $\mu \sim N(\mu_0, \sigma_0^2)$ ,

则后验分布为

$$\mu|\mathbf{x} \sim N\left(\frac{\mu_0\tau_0 + n\bar{x}\tau}{\tau_0 + n\tau}, \frac{1}{\tau_0 + n\tau}\right)$$

记为  $\mu|\mathbf{x} \sim N(\mu_n, \sigma_n^2)$ , 其中  $\tau = 1/\sigma^2$  为总体分布（一个样本）的精度,  $\tau_0 = 1/\sigma_0^2$  为先验分布的精度。

正态模型（方差已知）：后验均值

- 后验均值: 收缩估计

$$\begin{aligned} E(\mu|\mathbf{x}) &= \frac{\mu_0\tau_0 + n\bar{x}\tau}{\tau_0 + n\tau} \\ &= w\mu_0 + (1 - w)\bar{x} \end{aligned}$$

- 权重  $w = \tau_0/(\tau_0 + n\tau)$
- 当数据  $n \rightarrow \infty$  时,  $w \rightarrow 0$ , 此时  $\theta|\mathbf{x} \approx N(\bar{x}, \sigma^2/n)$
- 当数据  $n \approx 0$  时,  $w = 1$ , 此时  $\theta|\mathbf{x} \approx N(\mu_0, \sigma_0^2)$

正态模型（方差已知）：后验方差和精度

- 后验分布的方差:

$$D(\mu|\mathbf{x}) = \frac{1}{\tau_0 + n\tau} = \frac{\sigma_0^2\sigma^2}{n\sigma_0^2 + \sigma^2}$$

- 后验精度  $= \tau_0 + n\tau =$  先验精度  $(1/\sigma_0^2) +$  数据精度  $(n/\sigma^2)$
- 当先验精度  $\tau_0 \approx 0$ , 此时  $\theta|\mathbf{x} \approx N(\bar{x}, \sigma^2/n)$
- 当先验精度  $\tau_0 \approx \infty$ ,  $D(\mu|\mathbf{x}) \rightarrow 0$ , 此时  $\theta|\mathbf{x} \approx \mu_0$

## 正态模型（方差已知）：预测分布

- 后验分布为:  $\mu|\mathbf{y} \sim N(\mu_n, \sigma_n^2)$
- 设  $\tilde{y}$  是一个未来观察值, 则  $\tilde{y}|\mu \sim N(\mu, \sigma^2)$ 。  $\tilde{y}$  的后验预测均值和方差为:

$$\begin{aligned} E(\tilde{y}|\mathbf{y}) &= E[E(\tilde{y}|\mu)|\mathbf{y}] = E(\mu|\mathbf{y}) = \mu_n \\ \text{Var}(\tilde{y}|\mathbf{y}) &= \text{Var}[E(\tilde{y}|\mu)|\mathbf{y}] + E[\text{Var}(\tilde{y}|\mu)|\mathbf{y}] \\ &= \text{Var}(\mu|\mathbf{y}) + E(\sigma^2|\mathbf{y}) \\ &= \sigma_n^2 + \sigma^2 \end{aligned}$$

即  $\tilde{y}|\mathbf{y} \sim N(\mu_n, \sigma_n^2 + \sigma^2)$

- 简捷推导:  $\tilde{y}|\mathbf{y} = (\tilde{y} - \mu)|\mathbf{y} + \mu|\mathbf{y}$
- 不确定性两个来源: 后验分布 + 未来观测值

## 1.2 方差未知

### 正态模型（方差未知）：逆伽玛-正态模型

假设观察值  $\mathbf{x} = (x_1, \dots, x_n)'$  来自正态总体  $N(\mu, \sigma^2)$ ,  $\sigma^2$  未知,  $\mu$  已知。如何确定  $\sigma^2$  的共轭先验分布?

似然函数:

$$\begin{aligned} L(\sigma^2|\mathbf{x}) &\propto \sigma^{-n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right) \\ &= (\sigma^2)^{-n/2} \exp\left(-\frac{T}{2\sigma^2}\right) \end{aligned}$$

其中  $T$  为充分统计量  $T = \sum (x_i - \mu)^2$   
共轭先验的 pdf 应该有如下形式:

$$\pi(\sigma^2) \propto (\sigma^2)^{-(\alpha+1)} \exp\left(-\frac{\beta}{\sigma^2}\right)$$

### 逆伽玛分布

**定义 2** (Inverse-Gamma). 如果  $1/X \sim \text{Gamma}(\alpha, \beta)$ , 则称  $X$  服从逆伽玛分布, 记为  $X \sim \text{IG}(\alpha, \beta)$  分布, 其 pdf 为:

$$f(x|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{-(\alpha+1)} \exp(-\beta/x), (\alpha > 0, \beta > 0)$$

- $E(X) = \beta/(\alpha - 1)$ ,  $\alpha > 1$
- $D(X) = \frac{\alpha^2}{(\alpha-1)^2(\alpha-2)}$ ,  $\alpha > 2$
- If  $X \sim \text{IG}(\alpha, \beta)$ , then  $1/X \sim \text{Gamma}(\alpha, \beta)$
- If  $X \sim \text{IG}(\nu/2, \nu s^2/2)$ , then  $\nu s^2/X \sim \chi^2(\nu)$

### 正态模型（方差未知）：逆伽玛-正态模型

**事实 1** (方差的后验分布). 假设观察值  $\mathbf{x} = (x_1, \dots, x_n)'$  来自总体  $N(\mu, \sigma^2)$ ,  $\sigma^2$  未知,  $\mu$  已知。

假设先验:  $\sigma^2 \sim \text{IG}(\nu_0/2, \nu_0\sigma_0^2/2)$ ,

则后验分布为:

$$\sigma^2 | \mathbf{x} \sim \text{IG}((\nu_0 + n)/2, (\nu_0\sigma_0^2 + T)/2)$$

其中  $T = \sum_{i=1}^n (x_i - \mu)^2$

- 为共轭先验
- 后验分布也可以用  $\chi^2$  分布表示

### $\chi^2$ 分布

**定义 3** ( $\chi^2$ -分布). 称  $X \sim \chi^2(\nu)$ , 如果  $X = \sum_{i=1}^{\nu} X_i^2$ , 其中  $X_1, X_2, \dots, X_{\nu}$  为独立同分布的标准正态分布, 其 pdf 为

$$f(x) = \frac{(1/2)^{\nu/2}}{\Gamma(\nu/2)} x^{\nu/2-1} e^{-x/2} (x > 0; \nu > 0)$$

**定义 4** ( $\text{Inv-}\chi^2$ ). 称  $X \sim \text{Inv-}\chi^2(\nu)$  if  $1/X \sim \chi^2(\nu)$

**定义 5** ( $\text{Scaled-Inv-}\chi^2$ ). 称  $X \sim \text{Scaled-Inv-}\chi^2(\nu, s^2)$  if  $\nu s^2/X \sim \chi^2(\nu)$

### Some Properties

- If  $X \sim \chi(\nu)$ , then  $E(X) = \nu$ ,  $D(X) = 2\nu$
- If  $X_i \stackrel{iid}{\sim} N(0, 1)$ ,  $i = 1, 2, \dots, \nu$ , then  $X = \sum_{i=1}^{\nu} X_i^2 \sim \chi^2(\nu)$
- If  $X \sim \text{IG}(\nu/2, 1/2)$ , then  $X \sim \text{Inv-}\chi^2(\nu)$
- If  $X \sim \text{Inv-}\chi^2(\nu)$ , then  $X \sim \text{Scaled-Inv-}\chi^2(\nu, 1/\nu)$
- If  $\sigma^2 \sim \text{IG}(\nu_0/2, \nu_0\sigma_0^2/2)$ , then  $\nu_0\sigma_0^2/\sigma^2 \sim \chi^2(\nu)$ ,  
or  $\sigma^2 \sim \text{Scaled-Inv-}\chi^2(\nu_0, \sigma_0^2)$

### 正态模型（方差未知）：逆卡方-正态模型

**事实 2** (方差的后验分布). 假设观察值  $\mathbf{x} = (x_1, \dots, x_n)'$  来自正态总体  $N(\mu, \sigma^2)$ ,  $\sigma^2$  未知,  $\mu$  已知。

假设先验:  $\sigma^2 \sim \text{Scaled-Inv-}\chi^2(\nu_0, \sigma_0^2)$

则后验分布为:

$$\sigma^2 | \mathbf{x} \sim \text{Scaled-Inv-}\chi^2(\nu_0 + n, \nu_0\sigma_0^2 + T)$$

- 为共轭先验

## 2 一元正态模型 (多参数: 均值与方差都未知)

### 多参数模型

- 多参数贝叶斯模型:
  - 似然函数  $L(\boldsymbol{\theta}|\mathbf{y})$ : 总体  $Y \sim f(y|\boldsymbol{\theta})$ , 其中  $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_p)^T$  为  $p$  维未知参数向量,  $y_1, y_2, \dots, y_n$  为样本观察值,
$$L(\boldsymbol{\theta}|\mathbf{y}) = \prod_{i=1}^n f(y_i|\boldsymbol{\theta})$$
  - 先验分布:  $\boldsymbol{\theta} \sim \pi(\boldsymbol{\theta})$
  - 后验分布:  $p(\boldsymbol{\theta}|\mathbf{y}) \propto \pi(\boldsymbol{\theta})L(\boldsymbol{\theta}|\mathbf{y})$
- Bad news:
  - 实际应用中不容易明确多元参数  $\boldsymbol{\theta}$  的先验分布;
  - 计算困难, 因为涉及多重积分。

### 如果有多余参数

- 现实中有多个未知参数, 但只有一个或少数几个参数是我们感兴趣的
  - $\boldsymbol{\theta} = (\theta_1, \theta_2)^T$ , 对  $\theta_1$  感兴趣
  - $\theta_2$  称为**多余参数** (Nuisance parameter)
- 如何对  $\theta_1$  进行贝叶斯推断?
  - 联合后验分布对多余参数平均, 得到  $\theta_1$  的边缘后验分布

$$\begin{aligned} p(\theta_1|\mathbf{y}) &= \int p(\theta_1, \theta_2|\mathbf{y}) d\theta_2 \\ &= \int p(\theta_1|\theta_2, \mathbf{y}) p(\theta_2|\mathbf{y}) d\theta_2 \end{aligned}$$

- $p(\theta_1|\mathbf{y})$  含义: 给定  $\theta_2$  条件下, 对所有可能的  $\theta_2$  进行加权平均, 权重函数为  $p(\theta_2|\mathbf{y})$
- 一般情形下, 以上积分没有显式解, 需要随机模拟。

### 正态分布 (均值、方差未知) 的贝叶斯分析

正态模型  $N(\mu, \sigma^2)$ : 均值和方差均未知。

- 如何给定  $(\mu, \sigma^2)$  联合先验分布?
  - 无信息先验
  - 共轭先验
- 如何对参数进行贝叶斯推断?
  - $\mu$  的边缘后验分布  $\mu|\mathbf{y}$ ?
  - $\sigma^2$  的边缘后验分布  $\sigma^2|\mathbf{y}$ ?
  - 预测分布  $\hat{y}|\mathbf{y}$ ?

## 2.1 无信息先验

### 联合后验分布

设  $Y \sim N(\mu, \sigma^2)$ ,  $\mu$  和  $\sigma^2$  未知。  $\mathbf{y} = (y_1, y_2, \dots, y_n)'$ , 对  $\mu$  感兴趣,  $\sigma^2$  为多余参数

- 位置-尺度参数的 Jeffreys 无信息先验:

$$\pi(\mu, \sigma^2) \propto 1/\sigma^2$$

- 联合后验分布:

$$\begin{aligned} p(\mu, \sigma^2 | \mathbf{y}) &\propto \pi(\mu, \sigma^2) f(\mathbf{y} | \mu, \sigma^2) \\ &\propto \sigma^{-(n+2)} \exp\left\{-\frac{1}{2\sigma^2} [(n-1)s^2 + n(\bar{y} - \mu)^2]\right\} \end{aligned}$$

其中  $s^2$  为样本方差  $s^2 = \frac{1}{n-1} \sum (y_i - \bar{y})^2$

- $(\bar{y}, s^2)$  是充分统计量 (Sufficient statistics)
- Q:  $\mu$  和  $\sigma^2$  的后验分布是否相互独立?

### 方差的 $\sigma^2$ 边缘后验分布

- $\sigma^2$  的边缘后验分布:

$$\begin{aligned} p(\sigma^2 | \mathbf{y}) &= \int p(\mu, \sigma^2 | \mathbf{y}) d\mu \\ &\propto (\sigma^2)^{-\frac{n+1}{2}} \exp\left[-\frac{(n-1)s^2}{2\sigma^2}\right] \end{aligned}$$

- 即  $\sigma^2 | \mathbf{y} \sim \text{IG}(\frac{n-1}{2}, \frac{n-1}{2} s^2)$ ,
- 亦即  $\sigma^2 | \mathbf{y} \sim \text{Scaled-inv} - \chi^2(n-1, s^2)$ ,
- 亦即

$$\frac{(n-1)s^2}{\sigma^2} \Big| \mathbf{y} \sim \chi^2(n-1)$$

### 均值 $\mu$ 的边缘后验分布

- $\mu$  的后验条件分布

$$\mu | \sigma^2, \mathbf{y} \sim N(\bar{y}, \frac{\sigma^2}{n})$$

- $\mu$  的边缘后验分布

$$\begin{aligned}
p(\mu|\mathbf{y}) &= \int p(\mu|\sigma^2, \mathbf{y})p(\sigma^2|\mathbf{y})d\sigma^2 \\
&\propto \left[1 + \frac{n(\bar{y} - \mu)^2}{(n-1)s^2}\right]^{-n/2}
\end{aligned}$$

即  $\mu|\mathbf{y} \sim t_{(n-1)}(\bar{y}, s^2/n)$ , 或

$$\frac{\mu - \bar{y}}{s/\sqrt{n}}|\mathbf{y} \sim t(n-1)$$

- 结果等价于频率学派, 但解释不同

### 一般 $t$ -分布的定义

定义 6. 一个随机变量称为  $T \sim t_\nu(\mu, \sigma^2)$ , 如果  $T = \mu + \sigma Z$ , 其中  $Z$  为标准  $t$ -分布, 其  $pdf$  为

$$f(t|\nu, \mu, \sigma^2) = \frac{\Gamma[(\nu+1)/2]}{(\sigma^2\nu\pi)^{1/2}\Gamma(\nu/2)} \left[1 + \frac{(t-\mu)^2}{\nu\sigma^2}\right]^{-(\nu+1)/2}$$

其中  $\nu$  为自由度,  $\mu$  为位置参数,  $\sigma$  为尺度参数。

$$E(T) = \mu \quad (\nu > 1)$$

$$Var(T) = \frac{\nu\sigma^2}{\nu-2} \quad (\nu > 2)$$

如果  $\mu = 0, \sigma^2 = 1$ , 则为标准  $t$ -分布:  $T \sim t(\nu)$ 。

### 预测分布

- 预测分布  $\tilde{y}|\mathbf{y}$ :

$$\begin{aligned}
p(\tilde{y}|\mathbf{y}) &= \iint f(\tilde{y}|\mu, \sigma^2, \mathbf{y})p(\mu, \sigma^2|\mathbf{y})d\mu d\sigma^2 \\
&= \int \left[ \int f(\tilde{y}|\mu, \sigma^2, \mathbf{y})p(\mu|\sigma^2, \mathbf{y})d\mu \right] p(\sigma^2|\mathbf{y})d\sigma^2 \\
&= \int p(\tilde{y}|\sigma^2, \mathbf{y})p(\sigma^2|\mathbf{y})d\sigma^2
\end{aligned}$$

- 需要先求  $\tilde{y}|\mathbf{y}, \sigma^2$  的分布。方差已知时, 先验  $\mu \sim N(\mu_0, \sigma_0^2)$ , 预测分布为  $\tilde{y}|\mathbf{y}, \sigma^2 \sim N(\mu_n, \sigma_n^2)$ , 无信息先验相当于  $\sigma_0^2 \rightarrow \infty$ , 此时, 预测分布为:  $\tilde{y}|\mathbf{y}, \sigma^2 \sim N[\bar{y}, (1 + \frac{1}{n})\sigma^2]$
- 预测分布  $\tilde{y}|\mathbf{y}$  (与  $\mu|\mathbf{y}$  推导类似):

$$\tilde{y}|\mathbf{y} \sim t_{n-1}[\bar{y}, (1 + \frac{1}{n})s^2]$$

### 巴菲特：投资收益率


巴菲特从 1965-2012 年投资年回报率的均值为 20.65，标准差为 14.52。假设年回报率  $y \sim N(\mu, \sigma^2)$ ，采用无信息先验。

1. 平均回报率  $\mu$  的分布及估计；
2. 投资风险值  $\sigma^2$  的分布及估计；
3. 预测巴菲特 2013 年的投资收益率。

### 巴菲特：平均回报率

$$\mu | \mathbf{y} \sim t_{(n-1)}(\bar{y}, s^2/n) = t_{47}(20.52, 4.39), \quad n = 48, \quad \bar{y} = 20.52, \quad s = 14.52$$

- 点估计:  $\hat{\mu} = \bar{y} = 20.65$
- 95% 可信区间: [16.77, 26.33]



### 巴菲特：方差（风险）

$$\begin{aligned} \frac{(n-1)s^2}{\sigma^2} | \mathbf{y} &\sim \chi^2(n-1) \\ \sigma^2 | \mathbf{y} &= \frac{(n-1)s^2}{\chi^2(n-1)} \sim \text{Scaled - inv - } \chi^2(n-1, s^2) \end{aligned}$$

用模拟的方法：

1. 抽取 N 个样本: `chisq<-rchisq(N,n-1)`
2. 计算: `V<-(n-1)*s^2/chisq`
3. 计算 95% 区间: `quantile(V,c(0.025,0.975))`  
结果: N=100000, 95%CI: [146 331]



巴菲特：预测

预测分布： $\tilde{y}|\mathbf{y} \sim t_{n-1}[\bar{y}, (1 + \frac{1}{n})s^2] = t_{47}(20.65, 215.22)$

点预测： $E(\tilde{y}|\mathbf{y}) = \bar{y} = 20.65$ ,

预测区间： $[-8.99, 50.033]$


$$\bar{y} - st_{\alpha/2}(n-1)\sqrt{1 + \frac{1}{n}} \leq \tilde{y} \leq \bar{y} + st_{\alpha/2}(n-1)\sqrt{1 + \frac{1}{n}}$$

R codes:

```
tcrt<-qt(c(.025,.975),n-1)
```

```
CI<-ybar+s*tcrt*sqrt(1+1/n)
```

巴菲特：预测分布



## 2.2 共轭先验

联合先验分布

- 模型  $y_1, \dots, y_n \sim N(\mu, \sigma^2)$  ,  $\mu$  和  $\sigma^2$  未知。
- 先验分布:

$$\mu|\sigma^2 \sim N(\mu_0, \frac{\sigma^2}{k_0}), \sigma^2 \sim \text{Inv} - \chi^2(\nu_0, \sigma_0^2)$$

联合先验分布

$$\pi(\mu, \sigma^2) \propto \frac{1}{\sigma} \frac{1}{(\sigma^2)^{\nu_0/2+1}} \exp\left(-\frac{1}{2\sigma^2}[\nu_0\sigma_0^2 + k_0(\mu - \mu_0)^2]\right)$$

- 称为: Normal-Inv- $\chi^2$  分布
- $\mu$  与  $\sigma^2$  独立吗?

联合后验分布

- 联合后验分布:

$$p(\mu, \sigma^2 | \mathbf{y}) \propto \frac{1}{\sigma} \frac{1}{(\sigma^2)^{\nu_n/2+1}} \exp\left(-\frac{1}{2\sigma^2}[\nu_n\sigma_n^2 + k_n(\mu - \mu_n)^2]\right)$$

其中

$$\begin{aligned}\mu_n &= \frac{k_0}{k_0 + n}\mu_0 + \frac{n}{k_0 + n}\bar{y} \\ k_n &= k_0 + n \\ \nu_n &= \nu_0 + n \\ \nu_n\sigma_n^2 &= \nu_0\sigma_0^2 + (n-1)s^2 + \frac{k_0n}{k_0 + n}(\bar{y} - \mu_0)^2\end{aligned}$$

- 也是 Normal-Inv- $\chi^2$  分布, 所以共轭。

$\mu$  的条件后验

- 条件后验分布:  $p(\mu | \sigma^2, \mathbf{y})$

$$\mu | \sigma^2, \mathbf{y} \sim N(\mu_n, \sigma_n^2)$$

其中

$$\mu_n = \frac{\frac{k_0}{\sigma^2}\mu_0 + \frac{n}{\sigma^2}\bar{y}}{\frac{k_0}{\sigma^2} + \frac{n}{\sigma^2}} \quad \sigma_n^2 = \frac{1}{\frac{k_0}{\sigma^2} + \frac{n}{\sigma^2}}$$

- 与方差已知情形结果一致

$\mu$  和  $\sigma^2$  的边缘后验

- 方差  $\sigma^2$  的后验分布:

$$\sigma^2 | \mathbf{y} \sim \text{Scaled-inv-}\chi^2(\nu_n, \sigma_n^2)$$

- 均值  $\mu$  的边缘后验分布:

$$\mu | \mathbf{y} \sim t_{\nu_n}\left(\mu_n, \frac{\sigma_n^2}{k_n}\right)$$

小结：一元正态（均值、方差未知）的贝叶斯分析

A. 无信息先验： $\pi(\mu, \sigma^2) \propto 1/\sigma^2$

- $\sigma^2$  的边缘后验分布  $\sigma^2|\mathbf{y}$ ?

$$- \sigma^2|\mathbf{y} \sim \text{Inv-Gamma}\left(\frac{n-1}{2}, \frac{n-1}{2}s^2\right) = \text{Scaled-inv-}\chi^2(n-1, s^2)$$

- $\mu$  的边缘后验分布  $\mu|\mathbf{y}$ ?

$$- \mu|\mathbf{y} \sim t_{n-1}(\bar{y}, s^2/n)$$

- 预测分布  $\tilde{y}|\mathbf{y}$ ?

$$- \tilde{y}|\mathbf{y} \sim t_{n-1}[\bar{y}, (1 + \frac{1}{n})s^2]$$

小结：一元正态（均值、方差未知）的贝叶斯分析

B. 共轭先验： $\mu|\sigma^2 \sim N(\mu_0, \frac{\sigma^2}{k_0})$ ,  $\sigma^2 \sim \text{Inv-}\chi^2(\nu_0, \sigma_0^2)$

- $\sigma^2$  的边缘后验分布：

$$\sigma^2|\mathbf{y} \sim \text{Scaled-inv-}\chi^2(\nu_n, \sigma_n^2)$$

- $\mu$  的条件后验分布：

$$\mu|\sigma^2, \mathbf{y} \sim N(\mu_n, \frac{\sigma_n^2}{k_n})$$

- $\mu$  的边缘后验分布：

$$\mu|\mathbf{y} \sim t_{\nu_n}\left(\mu_n, \frac{\sigma_n^2}{k_n}\right)$$

### 3 多元正态模型

#### 3.1 多元正态分布及 Wishart 分布

多元正态分布的密度函数及似然函数

定义 7. 称  $p$  维随机向量  $\mathbf{y} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , 如果

$$f(\mathbf{y}|\boldsymbol{\mu}, \Sigma) \propto |\Sigma|^{-1/2} \exp\left(-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{y} - \boldsymbol{\mu})\right)$$

设有  $n$  个样本观察向量  $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$ , 则似然函数为

$$\begin{aligned} L(\boldsymbol{\mu}, \Sigma|\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n) &\propto |\Sigma|^{-1/2} \exp\left(-\frac{1}{2} \sum (\mathbf{y}_i - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{y}_i - \boldsymbol{\mu})\right) \\ &= |\Sigma|^{-1/2} \exp\left(-\frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{S}_0)\right) \end{aligned}$$

其中  $\mathbf{S}_0 = \sum_{i=1}^n (\mathbf{y}_i - \boldsymbol{\mu})(\mathbf{y}_i - \boldsymbol{\mu})^T$

## Wishart and Inverse Wishart

定义 8 (Wishart 分布). 称  $p \times p$  随机矩阵  $\mathbf{X} \sim \text{Wishart}_p(\Sigma, \nu)$ , 如果其 pdf 为

$$f(\mathbf{X}) = \frac{|\mathbf{X}|^{\frac{\nu-p-1}{2}}}{2^{\frac{\nu p}{2}} |\Sigma|^{\frac{p}{2}} \Gamma_p(\frac{\nu}{2})} \exp\left[-\frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{X})\right]$$

1. 如果  $\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n \stackrel{iid}{\sim} N_p(0, \Sigma)$ ,  $\mathbf{X} = \sum_{i=1}^n \mathbf{z}_i \mathbf{z}_i^T \sim \text{Wishart}_p(\Sigma, n)$
2. 一维:  $z_1, z_2, \dots, z_n \stackrel{iid}{\sim} N(0, \sigma^2)$ , then  $X = \sum z_i^2 \sim \sigma^2 \chi_n^2$
3.  $E(\mathbf{X}) = \nu \Sigma$ ,  $D(X_{ij}) = \nu(\sigma_{ij}^2 + \sigma_{ii} \sigma_{jj})$

定义 9 (Inverse Wishart). 称  $\mathbf{X} \sim \text{Inv-Wishart}_p(\Lambda, \nu)$ , 如果  $\mathbf{X}^{-1} \sim \text{Wishart}_p(\Lambda^{-1}, \nu)$

- $E(\mathbf{X}) = \Lambda/(\nu - p - 1)$ ,  $\text{Mod}(\mathbf{X}) = \Lambda/(\nu + p + 1)$

## 3.2 多元正态模型 (协差阵 $\Sigma$ 已知)

多元正态 (协差阵已知): 共轭先验

模型:  $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n \sim N_p(\boldsymbol{\mu}, \Sigma)$ ,  $\Sigma$  已知。

先验:  $\boldsymbol{\mu} \sim N_p(\boldsymbol{\mu}_0, \Lambda_0)$ 。

- 后验分布

$$\boldsymbol{\mu} | \mathbf{y} \sim N_p(\boldsymbol{\mu}_n, \Lambda_n)$$

其中

$$\begin{aligned} \boldsymbol{\mu}_n &= \Lambda_n (\Lambda_0^{-1} \boldsymbol{\mu}_0 + n \Sigma^{-1} \bar{\mathbf{y}}) \\ \Lambda_n &= (\Lambda_0^{-1} \boldsymbol{\mu}_0 + n \Sigma^{-1})^{-1} \end{aligned}$$

- 预测分布

$$\tilde{\mathbf{y}} | \mathbf{y} \sim N_p(\boldsymbol{\mu}_n, \Lambda_n + \Sigma)$$

- 与一维情形类似

## 3.3 多元正态模型 (协差阵 $\Sigma$ 未知)

多元正态 (协差阵未知, 均值为 0)

设  $\mathbf{Y}_1, \mathbf{Y}_2, \dots, \mathbf{Y}_n \stackrel{iid}{\sim} N(0, \Sigma)$ , 先验分布  $\Sigma \sim \text{Inv-Wishart}_p(\Lambda_0^{-1}, \nu_0)$ , 则  $\Sigma$  的后验分布为

$$\Sigma | \mathbf{Y} \sim \text{Inv-Wishart}_p(\mathbf{S} + \Lambda_0^{-1}, n + \nu_0)$$

其中  $\mathbf{S} = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}})(\mathbf{y}_i - \bar{\mathbf{y}})'$

多元正态（协差阵与均值均未知）：Jeffreys 无信息先验

无信息先验 (Jeffreys):

$$\pi(\boldsymbol{\mu}, \Sigma) \propto |\Sigma|^{-(p+1)/2}$$

- 后验分布:

$$\begin{aligned}\Sigma|\mathbf{y} &\sim \text{Inv-Wishart}_p(\mathbf{S}, n-1) \\ \boldsymbol{\mu}|\Sigma, \mathbf{y} &\sim \text{N}_p(\bar{\mathbf{y}}, \Sigma/n)\end{aligned}$$

- 边缘后验  $\boldsymbol{\mu}|\mathbf{y}$ :

$$\boldsymbol{\mu}|\mathbf{y} \sim t_{n-p}[\bar{\mathbf{y}}, \mathbf{S}/(n(n-p))]$$

多元  $t$  分布的定义

定义 10 (多元  $t$  分布). 称  $p$  维随机向量  $\mathbf{y} \sim t_\nu(\boldsymbol{\mu}, \Sigma)$ , 如果

$$f(\mathbf{y}) \propto \left(1 + \frac{1}{\nu}(\mathbf{y} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{y} - \boldsymbol{\mu})\right)^{-(\nu+k)/2}$$

其中  $\nu$  自由度,  $\boldsymbol{\mu}$  为位置参数,  $\Sigma$  为尺度参数的平方。

多元正态（协差阵与均值均未知）：共轭先验

先验: Normal-Inv-Wishart 分布

$$\begin{aligned}\Sigma &\sim \text{Inv-Wishart}_p(\Lambda_0^{-1}, \nu_0) \\ \boldsymbol{\mu}|\Sigma &\sim \text{N}_p(\boldsymbol{\mu}_0, \Sigma/k_0)\end{aligned}$$

其中  $k_0/n$  越小表示先验所占比重越小。

- 后验分布:

$$\begin{aligned}\Sigma|\mathbf{y} &\sim \text{Inv-Wishart}_p(\Lambda_n^{-1}, \nu_n) \\ \boldsymbol{\mu}|\Sigma, \mathbf{y} &\sim \text{N}_p(\boldsymbol{\mu}_n, \Sigma/k_n)\end{aligned}$$

- 边缘后验  $\boldsymbol{\mu}|\mathbf{y}$ :

$$\boldsymbol{\mu}|\mathbf{y} \sim t_{\nu_n-p+1}\left(\boldsymbol{\mu}_n, \frac{\Lambda_n}{k_n(\nu_n-p+1)}\right)$$

- 预测分布:

$$\tilde{\mathbf{y}}|\mathbf{y} \sim t_{\nu_n-p+1}\left(\boldsymbol{\mu}_n, \frac{\Lambda_n + k_n + 1}{k_n(\nu_n-p+1)}\right)$$

多元正态（协差阵与均值均未知）：共轭先验

其中

$$\begin{aligned}\boldsymbol{\mu}_n &= \frac{k_0}{k_0 + n} \boldsymbol{\mu}_0 + \frac{n}{k_0 + n} \bar{\mathbf{y}} \\ k_n &= k_0 + n \\ \nu_n &= \nu_0 + n \\ \Lambda_n &= \Lambda_0 + \mathbf{S} + \frac{k_0 n}{k_0 + n} (\bar{\mathbf{y}} - \boldsymbol{\mu}_0)(\bar{\mathbf{y}} - \boldsymbol{\mu}_0)^T\end{aligned}$$

- 当  $k_0 \rightarrow 0$ ,  $\nu_0 \rightarrow -1$  及  $|\Sigma_0| \rightarrow 0$ , 共轭先验 = 无信息先验

小结：多元正态分布的贝叶斯模型

1.  $\boldsymbol{\mu}$  未知,  $\Sigma$  已知

- 正态先验:  $\boldsymbol{\mu} \sim N_p(\boldsymbol{\mu}_0, \Lambda_0)$
- 后验:  $\boldsymbol{\mu} | \mathbf{y} \sim N_p(\boldsymbol{\mu}_n, \Lambda_n)$

2.  $\boldsymbol{\mu}, \Sigma$  均未知

- 无信息先验:  $\pi(\boldsymbol{\mu}, \Sigma) \propto |\Sigma|^{(p+1)/2}$   
 $\Sigma | \mathbf{y} \sim \text{Inv-Wishart}_p(\mathbf{S}, n-1)$   
 $\boldsymbol{\mu} | \Sigma, \mathbf{y} \sim N_p(\bar{\mathbf{y}}, \Sigma/n)$   
 $\boldsymbol{\mu} | \mathbf{y} \sim t_{n-p}[\bar{\mathbf{y}}, \mathbf{S}/(n(n-p))]$
- 共轭先验

$$\begin{aligned}\Sigma &\sim \text{Inv-Wishart}_p(\Lambda_0^{-1}, \nu_0), \quad \boldsymbol{\mu} | \Sigma \sim N_p(\boldsymbol{\mu}_0, \Sigma/k_0) \\ \Sigma | \mathbf{y} &\sim \text{Inv-Wishart}_{\nu_n}(\Lambda_n^{-1}); \boldsymbol{\mu} | \Sigma, \mathbf{y} \sim N_p(\boldsymbol{\mu}_n, \Sigma/k_n) \\ \boldsymbol{\mu} | \mathbf{y} &\sim \text{Multivariate } t_{\nu_n-p+1} \left( \boldsymbol{\mu}_n, \frac{\Lambda_n}{k_n(\nu_n-p+1)} \right)\end{aligned}$$

Recap

1. 一元正态模型（单参数）

- 方差已知：正态-正态模型
- 方差未知：逆伽玛-正态模型
- 方差未知：逆卡方-正态模型

2. 一元正态模型（多参数：均值和方差均未知）

- 无信息先验
- 共轭先验

3. 多元正态模型

- 均值  $\boldsymbol{\mu}$  未知, 协差阵  $\Sigma$  已知
- 均值  $\boldsymbol{\mu}$  和协差阵  $\Sigma$  均未知
  - 无信息先验
  - 共轭先验